3 Ajuste de Curvas - Método dos Mínimos Quadrados

Resumo: *A teoria de regressão permite que se estabeleçam relações entre variáveis de uma certa função que se deseja utilizar para ajustar uma distribuição de pontos, tal que a curva obtida a partir da função seja a melhor para aquele conjunto de dados. Dessa forma, procura-se compreender a natureza e o funcionamento de sistemas nas engenharias e nas ciências sociais que são descritas por meio dessas variáveis. Em muitas situações, conhece-se uma tabela de pontos (x_i, y_i), onde cada y_i é obtido experimentalmente, e deseja-se obter a expressão analítica de uma dada curva $y = f(x)$ que melhor se ajusta a esse conjunto de pontos. A expectativa é que os estudantes tenham a percepção do quão valiosa é a utilização do Método dos Mínimos Quadrados para o problema de predição numérica.*

Hipóteses

Em muitas situações, conhece-se uma tabela de pontos (x_i, y_i), onde cada y_i é obtido experimentalmente, e deseja-se obter a expressão analítica de uma dada curva $y = f(x)$ que melhor se ajusta a esse conjunto de pontos. Por exemplo, sabe-se que o número y de bactérias, por unidade de volume, existente em uma cultura após um determinado número x de horas, cresce exponencialmente com o aumento de x. Neste caso, o número de bactérias cresce com o decorrer das horas na forma $y = ae^{bx}$. O problema consiste então em determinar os valores apropriados dos parâmetros a e b desta exponencial.

Sendo assim, o método dos mínimos quadrados é uma técnica geral que se aplica para determinar os parâmetros de uma relação funcional entre duas ou mais grandezas de um fenômeno ou o valor mais provável de uma única grandeza medida várias vezes. Por exemplo, observando os dados experimentais representados na Figura (3.1), a relação funcional apresentada é do tipo linear. Os traços sobre a reta representa os desvios absolutos dos pontos à reta traçada, cuja soma dos quadrados desses desvios devem ser minimizados.

A derivação elementar dos mínimos quadrados recai no caso linear, na forma $y = a + bx$, sendo por hipótese y a variável dependente e x a variável independente.

Define-se o resíduo ou desvio (d) como $d_i = y_i - \hat{y}_i$, onde y_i refere-se aos valores medidos e $\hat{y} = a + bx_i$ ao valor calculado na reta do ajuste. O índice i refere-se a cada um dos n valores medidos.

Para que $\hat{y}$ seja a reta que melhor se ajusta aos dados, devemos minimizar a soma das diferenças entre os valores de y_i medidos e os valores da curva de ajuste $a+bx_i$ em cada ponto. Mas esta diferença pode ser tanto positiva quando negativa, o que pode ocasionar uma soma nula das diferenças, mesmo com os valores muito distantes da reta.

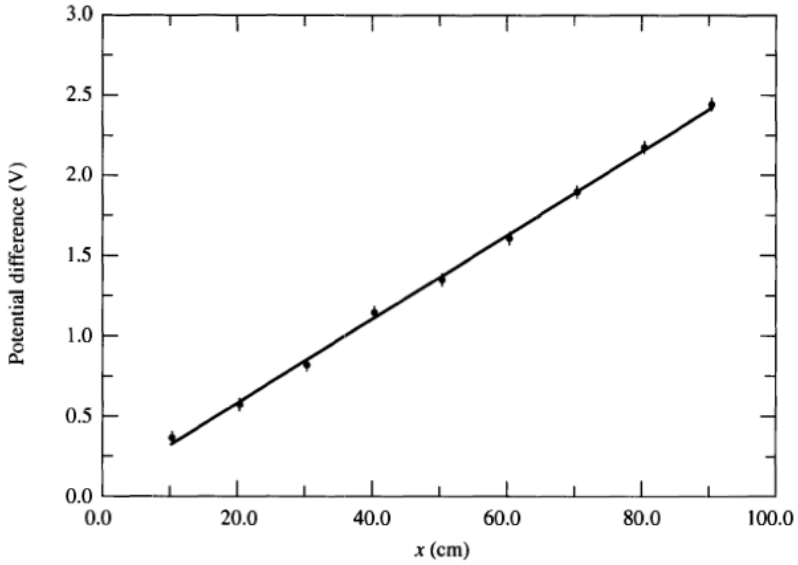


Figura 3.1: Diferença de potencial em função da posição ao longo de um condutor. Fonte: Bevington and Robinson (2003).

Uma forma de evitar o cancelamento é minimizar o quadrado da diferença. Poderíamos ainda ter escolhido minimizar o módulo da diferença, mas isto acarretaria em uma complicação nos cálculos, devido à necessidade de se obter as primeiras derivadas. Daí a escolha pela soma dos quadrados dos desvios. Então, supondo que temos n pontos medidos, definimos a função:

$$S = \sum_{i=1}^{n} (y_i - a - bx_i)^2$$

ou seja, a minimização dos somatório dos n desvios ao quadrado. De fato o que tentamos minimizar é S em relação aos parâmetros a e b, o que matematicamente implica que precisamos tomar a primeira derivada em relação aos parâmetros a e b, e esta derivada deve ser nula:

$$\frac{\partial S}{\partial a} = 0, \quad \text{e} \quad \frac{\partial S}{\partial b} = 0,$$

Ao fazermos isso, definimos o sistema de equações normais. Segue que:

$$\frac{\partial}{\partial a}\left[\sum_{i=1}^{n} (y_i - a - bx_i)^2\right] = 0$$
$$\frac{\partial}{\partial b}\left[\sum_{i=1}^{n} (y_i - a - bx_i)^2\right] = 0$$

Usando a propriedade de derivada de uma soma, temos:

$$\sum \frac{\partial}{\partial a}(a + bx_i - y_i)^2 = 0$$
$$\sum \frac{\partial}{\partial b}(a + bx_i - y_i)^2 = 0$$

Para não sobrecarregar a notação, retiramos o índice de contagem do somatório. Calculando as derivadas parciais, obtemos:

$$\sum 2(a + bx_i - y_i) = 0$$
$$\sum 2(a + bx_i - y_i) \cdot (x_i) = 0$$

Dividindo ambos os membros por 2, usando as propriedades do somatório e rearranjando os termos, obtemos:

$$a \sum 1 + b \sum x_i = \sum y_i$$
$$a \sum x_i + b \sum x_i^2 = \sum x_i y_i$$

A condição acima conduz a um sistema de duas equações e duas incógnitas a e b, permitindo portanto o cálculo destes parâmetros. Rescrevendo o sistema acima na forma matricial:

$$\begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \cdot \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}.$$

Chamando:

$$A = \begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix},$$

$$B = \begin{pmatrix} a \\ b \end{pmatrix}$$

e

$$D = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

podemos escrever:

$$A \cdot B = D$$

Como estamos interessados nos coeficientes a e b, temos que encontrar os valores dos elementos da matriz B - já que A e D são fornecidos!!!! Em outras palavras, temos que resolver a expressão:

$$B = A^{-1} \cdot D$$

e ficamos agora com o problema da matriz inversa. Usando o método dos determinantes, temos que a inversa a matriz A é dada pela expressão:

$$A^{-1} = \frac{1}{\sum 1 \sum x_i^2 - (\sum x_i)^2} \begin{pmatrix} \sum x_i^2 & -\sum x_i \\ -\sum x_i & \sum 1 \end{pmatrix}$$

e assim, obtemos para os valores de a e b:

$$\left.\begin{array}{ll} a = & \frac{1}{\Delta} \left(\sum x_i^2 \sum y_i - \sum x_i \sum x_i y_i \right) \\ b = & \frac{1}{\Delta} \left(\sum 1 \sum x_i y_i - \sum x_i \sum y_i \right) \end{array}\right\} \tag{3.1}$$

onde

$$\Delta = \sum 1 \sum x_i^2 - \left(\sum x_i \right)^2$$

Este método é conhecido como *método dos míminos quadrados*, e ele fornece a melhor reta, para o caso linear, que melhor ajusta os dados estudados.

3.1 Uma maneira mais computacional

As expressões obtidas na Equação (3.1), apesar de corretas, podem não parecer muito intuitivas na hora de se tentar resolver um problema real. Sendo assim, vamos apresentar uma forma alternativa de obter a solução do problema pelo método dos mínimos quadrados.

Vamos utilizar uma notação matricial, porém antes, vamos definir os desvios como sendo:

$$d_i = y_i - (a + bx_i)$$

e assim, definimos as seguintes matrizes:

$$B = \begin{bmatrix} a \\ b \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad D = \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix}, \quad e \quad A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}.$$

tal que

$$\begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

ou mais compactamente, como:

$$AB = Y$$

Segue que $y_i = a + bx_i$ para todo i variando de 1 até n é o mesmo que $AB = Y$. Assim, como queremos minimizar:

$$S(a, b) = \sum_{i=1}^{n} d_i^2$$

em notação matricial temos que:

$$\sum_{i=1}^{n} d_i^2 = D^T D$$

onde

$$D = Y - AB$$

Denotando $M = S(a, b)$, temos:

$$M = (Y - AB)^T (Y - AB) = Y^T Y - B^T A^T Y - Y^T AB + B^T A^T AB$$

Queremos obter os parâmetros a e b ou, na notação usada acima, o valor de B de modo que minimizamos M. Para isso, o gradiente de M (ou seja, a derivada primeira da função de duas variáveis M) deve ser nulo:

$$\begin{aligned} \nabla M = & - A^T Y - Y^T A + 2A^T AB = 0 \\ & - A^T Y - A^T Y + 2A^T AB = 0 \end{aligned}$$

ou

$$A^T AB = A^T Y$$

Como a matriz $A^T A$ é simétrica e definida positiva, o sistema linear admite solução única e e esta solução será o ponto crítico, ou neste caso o ponto mínimo.

Efetuando os cálculos, verificamos os valores de $A^T A$ e $A^T Y$, que são:

$$\begin{cases} A^T A &= \begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \\ A^T Y &= \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix} \end{cases}$$

Sendo assim, a expressão compacta a ser resolvida numericamente será:

$$B = (A^T A)^{-1} A^T Y \tag{3.2}$$

A expressão acima tem a vantagem de poder ser implementada numericamente, o que nos possibilitará desenvolver um software de predição.

3.1.1 Ajustando uma curva de dados

Na base de considerações teóricas ou simplesmente pelo padrão apresentado pelos pontos, decidimos a forma geral da curva $y = f(x)$ a ser ajustada. Algumas possibilidades são:

a) uma reta: $y = a + bx$;

b) um polinômio quadrático: $y = a + bx + cx^2$;

c) um polinômio cúbico: $y = a + bx + cx^2 + dx^3$.

Como os pontos são obtidos experimentalmente, geralmente temos algum *erro* de medição dos dados, tornando impossível encontrar uma curva da forma desejada que passe por todos os pontos. Assim, a idéia é escolher a curva (determinando seus coeficientes) que *melhor* ajusta os dados.

Exemplo 01: Encontre o ajuste linear de mínimos quadrados aos pontos (0, 1), (1, 3), (2, 4) e (3, 4).

Começamos identificando as matrizes:

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}; \quad \text{e} \quad Y = \begin{bmatrix} 1 \\ 3 \\ 4 \\ 4 \end{bmatrix}$$

tal que a nossa incógnita é:

$$B = \begin{bmatrix} a \\ b \end{bmatrix}.$$

A matriz transposta de A é dada por:

$$A^T = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \end{bmatrix}.$$

O produto entre a transposta e a matriz é:

$$A^T A = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 4 & 6 \\ 6 & 14 \end{bmatrix}$$

Já a inversa da matriz acima, considerando-se a regra do determinante é:

$$(A^T \cdot A)^{-1} = \frac{1}{20} \begin{bmatrix} 14 & -6 \\ -6 & 4 \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 7 & -3 \\ -3 & 2 \end{bmatrix}$$

tal que o valor de B pode ser obtido:

$$B = (A^T \cdot A)^{-1} A^T Y = \frac{1}{10} \begin{bmatrix} 7 & -3 \\ -3 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \\ 4 \\ 4 \end{bmatrix}$$

ou

$$B = \frac{1}{10} \begin{bmatrix} 7 & 4 & 1 & -2 \\ -3 & -1 & 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \\ 4 \\ 4 \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 15 \\ 10 \end{bmatrix} = \begin{bmatrix} 1.5 \\ 1.0 \end{bmatrix}$$

e portanto a reta desejada é:

$$y = 1.5 + 1.0x$$

3.2 Ajuste polinomial de mínimos quadrados

A técnica descrita para ajustar uma reta de mínimos quadrados pode ser generalizada para ajustar um polinômio de qualquer grau especificado. Sendo assim, vamos tentar ajustar um polinômio de grau fixo m:

$$y = a_0 + a_1 x + a_2 x^2 + \cdots + a_m x^m \tag{3.3}$$

aos n pontos:

$$(x_1, y_1), (x_2, y_2), \cdots, (x_n, y_n).$$

Substituindo esses n pontos na Equação (3.3), obteremos n equações:

$$\begin{cases} y_1 = & a_0 + a_1 x_1 + a_2 x_1^2 + \cdots + a_m x_1^m \\ y_2 = & a_0 + a_1 x_2 + a_2 x_2^2 + \cdots + a_m x_2^m \\ \vdots = & \vdots \\ y_n = & a_0 + a_1 x_n + a_2 x_n^2 + \cdots + a_m x_n^m \end{cases}$$

ou na forma matricial:

$$AB = \mathbf{Y}$$

onde

$$A = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \cdots & x_2^m \\ \vdots & \vdots & & \ddots & \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \text{e} \quad B = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix}$$

Como antes, a solução das equações normais é:

$$A^T AB = A^T Y.$$

que determina os coeficientes dos polinômios que minimizam

$$M = S(a_0, a_1, \cdots, a_n)$$

Exemplo 02 De acordo com a segunda lei do movimento de Newton, um corpo perto da superfície da Terra cai verticalmente para baixo de acordo com a equação:

$$S = S_0 + v_0 t + 1/2gt^2.$$

Suponha que é realizado um experimento em um laboratório para estimar g usando esta equação. Um peso é solto com velocidade e deslocamento iniciais desconhecidos e, em certos instantes, não medidas as distâncias que o peso caiu em relação a alguns pontos de referência fixado. Suponhamos que nos instantes $t = 0.1, 0.2, 0.3, 0.4$ e 0.5 segundos observa-se que o peso caiu $S = 0.18, 0.31, 1.03, 2.48$ e 3.73 pés, respectivamente, desde o ponto de referência. Encontre um valor aproximado de g usando estes dados.

O problema matemático é ajustar a curva quadrática:

$$S = S_0 + v_0 t + \frac{gt^2}{2}$$

aos cinco pontos dados:

$$(0.1, 0.18),\ (0.2, 0.31),\ (0.3, 1.03),\ (0.4, 2.48),\ \text{e}\ (0.5, 3.73)$$

Com as modificações apropriadas na notação, as matrizes A, B e Y são:

$$A = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ 1 & t_3 & t_3^2 \\ 1 & t_4 & t_4^2 \\ 1 & t_5 & t_5^2 \end{bmatrix} = \begin{bmatrix} 1 & 0.1 & 0.01 \\ 1 & 0.2 & 0.04 \\ 1 & 0.3 & 0.09 \\ 1 & 0.4 & 0.16 \\ 1 & 0.5 & 0.25 \end{bmatrix},$$

$$B = \begin{bmatrix} S_0 \\ v_0 \\ g \end{bmatrix}$$

e

$$Y = \begin{bmatrix} S_1 \\ S_2 \\ S_3 \\ S_4 \\ S_5 \end{bmatrix} = \begin{bmatrix} 0.18 \\ 0.31 \\ 1.03 \\ 2.48 \\ 3.73 \end{bmatrix}$$

Nosso objetivo é chegar à solução para a expressão matricial:

$$B = (A^T A)^{-1} A^T Y$$

Vamos calcular a matriz $A^T A$:

$$A^T A = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0.1 & 0.2 & 0.3 & 0.4 & 0.5 \\ 0.01 & 0.04 & 0.09 & 0.16 & 0.25 \end{bmatrix} \begin{bmatrix} 1 & 0.1 & 0.01 \\ 1 & 0.2 & 0.04 \\ 1 & 0.3 & 0.09 \\ 1 & 0.4 & 0.16 \\ 1 & 0.5 & 0.25 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 5 & 1.5 & 0.55 \\ 1.5 & 0.55 & 0.225 \\ 0.55 & 0.225 & 0.0979 \end{bmatrix}$$

Para calcularmos a matriz inversa vamos utilizar o processo de eliminação de Gauss, e assim encontramos:

$$(A^T A)^{-1} = \begin{bmatrix} 4.6 & -32.98 & 50.0 \\ -33.0 & 267.14 & -428.58 \\ 50.0 & -428.58 & 714.28 \end{bmatrix}.$$

E assim, podemos calcular B:

$$B = \begin{bmatrix} 4.6 & -32.98 & 50.0 \\ -33.0 & 267.14 & -428.58 \\ 50.0 & -428.58 & 714.28 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0.1 & 0.2 & 0.3 & 0.4 & 0.5 \\ 0.01 & 0.04 & 0.09 & 0.16 & 0.25 \end{bmatrix} \begin{bmatrix} 0.18 \\ 0.31 \\ 1.03 \\ 2.48 \\ 3.73 \end{bmatrix}$$

$$B = \begin{bmatrix} 1.8 & 0 & -0.8 & -0.59 & 0.6 \\ -10.6 & 3.33 & 8.57 & 5.29 & -6.57 \\ 14.28 & -7.15 & -14.30 & -7.14 & 14.28 \end{bmatrix} \begin{bmatrix} 0.18 \\ 0.31 \\ 1.03 \\ 2.48 \\ 3.73 \end{bmatrix}$$

$$B \backsimeq \begin{bmatrix} 0.27 \\ -3.43 \\ 21.18 \end{bmatrix}.$$

Logo, o valor procurado para a gravidade, lembrando que na expressão de ajuste temos $g/2$, é:

$$g \backsimeq 42.36 \ \text{pés/s}^2$$

3.3 Modelos não lieares

Em todo o procedimento desenvolvido até aqui, consideramos que a função de ajuste possuía coeficientes lineares, ou seja, expressamos as funções como uma soma de termos, cada um multiplicado por um simples coeficiente. Mas, como podemos ajustar dados com uma função que não possua coeficientes lineares? Por exemplo, vamos supor que possuímos dados cujo comportamento decaia

com o tempo, de uma situação de instabilidade para uma mais estável, e que a distribuição possa ser representada pela função normalizada:

$$f(t) = \frac{e^{-t/\tau}}{\tau},$$

onde τ é o tempo médio do estado instável desse sistema. Podemos encontrar o parâmetro τ com a técnica de mínimos quadrados? Bem, a dificuldade de se aplicar o procedimento de mínimos quadrados vem da tentativa de minimizar $\sum(y_i - ae^{-bx})$. O método dos mínimos quadrados não produz uma solução analítica exata para tais funções. No entanto, soluções aproximadas usando regressão linear podem ser obtidas.

Linearização da função

É possível transformar algumas funções em expressões lineares. Por exemplo, se o que desejamos é ajustar um problema de decaimento exponencial que obedeça a seguinte lei:

$$y = ae^{-bx} \tag{3.4}$$

onde a e b são parâmetros desconhecidos, o método que é utilizado normalmente quando se suspeita que os dados estejam relacionados exponencialmente é considerar o logaritmo de ambos os lados da equação de aproximação, ou seja:

$$\ln y = \ln a - bx. \tag{3.5}$$

Agora o problema torna-se linear e as soluções para $\ln a$ e b podem ser obtidas.

O método dos mínimos quadrados para minimizar o valor de S com relação aos coeficientes $\ln a$ e b é dado por:

$$S = \sum \left(\ln y_i - \ln A + bx_i\right)^2$$

Sendo,

$$d_i = \ln y_i - \ln a + bx_i$$

a definição das matrizes ficam:

$$A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad B = \begin{bmatrix} \ln a \\ b \end{bmatrix}, \quad e \quad Y = \begin{bmatrix} \ln y_1 \\ \ln y_2 \\ \vdots \\ \ln y_n \end{bmatrix}.$$

Logo, como já discutido acima, a solução dos parâmetros $\ln a$ e b podem ser obtidos através da expressão:

$$B = (A^T A)^{-1} A^T Y$$

Embora o método de tomar logaritmo de uma exponencial ou uma função de potência para produzir uma função que fica linear nos parâmetros possa ser conveniente para estimativas rápidas, com os computadores atuais, é preferível resolver esse tipo de problema através dos métodos de aproximação desenvolvida para funções não lineares.